Evolucionar los activos, resolver los pesos

Un enfoque híbrido de metaheurística y programación cuadrática para seleccionar carteras en universos grandes

Juan Pedro Enriquez y Eduardo Medina

Replica y amplía Hidalgo-Marín, Nebro y García-Nieto, *Efficient Selection of Investment Portfolios in Real-World Markets*, Algorithms 2026, 19, 20 [1]

1 El problema

Elegir k de N activos y sus pesos para minimizar el riesgo y maximizar el rendimiento:

$$\min\,(\sigma, -R), \quad \sigma = \sqrt{250\, w^{\top}\Sigma_S\, w}, \quad R = \textstyle\sum_{j\in S} w_j\mu_j$$

$$|S| = k, \qquad \textstyle\sum_j w_j = 1, \qquad \frac{1}{2k} \le w_j \le \frac{2}{k}$$

Las 12 instancias del artículo usan precios diarios de 2023 de activos cotizados en EE. UU. La mayor, **ALL_20_6000**, elige $k = 20$ de $N = 6000$.

El estudio original [1]

- NSGA-II, MOEA/D, SMS-EMOA y SMPSO (jMetal), 30 ejecuciones cada uno.
- Genes reales: k punteros a la lista de activos ordenada por rendimiento y k pesos.
- SMS-EMOA es el mejor. En ALL_20_6000 solo SMPSO alcanza el extremo de alto rendimiento.

Nuestra réplica (pymoo)

- Los tres algoritmos evolutivos con la configuración del artículo, 10 ejecuciones cada uno.
- Mismo orden y casi los mismos frentes (hipervolumen 0.944 en ambos en ALL_20_6000): las mejoras vienen de los cambios, no de la herramienta.

2 Qué cambiamos

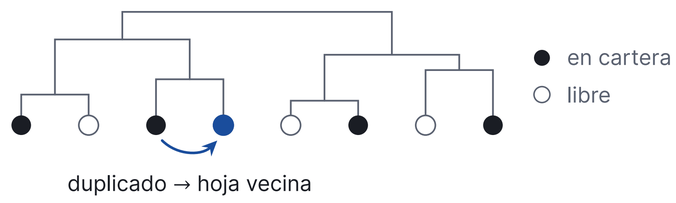
	Artículo original [1]	Este trabajo
Codificación	$2k$ reales: punteros $s_i \in [0,1]$ al activo $\lfloor s_i N \rfloor$ de la lista por rendimiento, más k pesos	**Por conjuntos**: k activos distintos y un gen de compromiso $t \in [0,1]$
Cruce	SBX en todos los genes ($p_c = 0.9$, $\eta = 20$)	**Uniforme por posiciones**: cada activo, de un padre
Mutación	Polinómica ($p_m = 1/n$, $\eta = 20$)	**Intercambio**: un activo por otro de fuera
Duplicados	Siguiente índice de la lista por rendimiento	**Reparación HRP**: siguiente hoja libre del dendrograma
Pesos	Evolucionados, luego normalizados y acotados	**Exactos**: un QP para los activos elegidos
Igual	algoritmos, parámetros, evaluaciones (50 000–250 000 por ejecución), semillas, objetivos, restricciones	

Reparación de colisiones HRP

El cruce por posiciones puede dar a un hijo el mismo activo dos veces. Como en Hierarchical Risk Parity [2], los activos se agrupan (enlace simple) según

$$d_{ij} = \sqrt{\tfrac{1}{2}\,(1 - \rho_{ij})}$$

El orden de las hojas junta a los activos correlacionados: un duplicado pasa a un sustituto cercano.

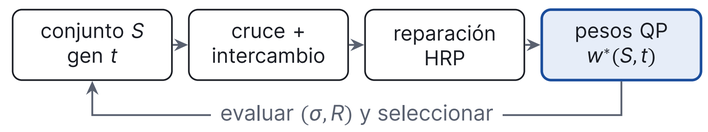


Pesos exactos: dividir el MIQP

La metaheurística elige la parte entera (qué activos). Lo que queda es un QP convexo en los 20 pesos, resuelto de forma exacta para cada cartera (quadprog [3]):

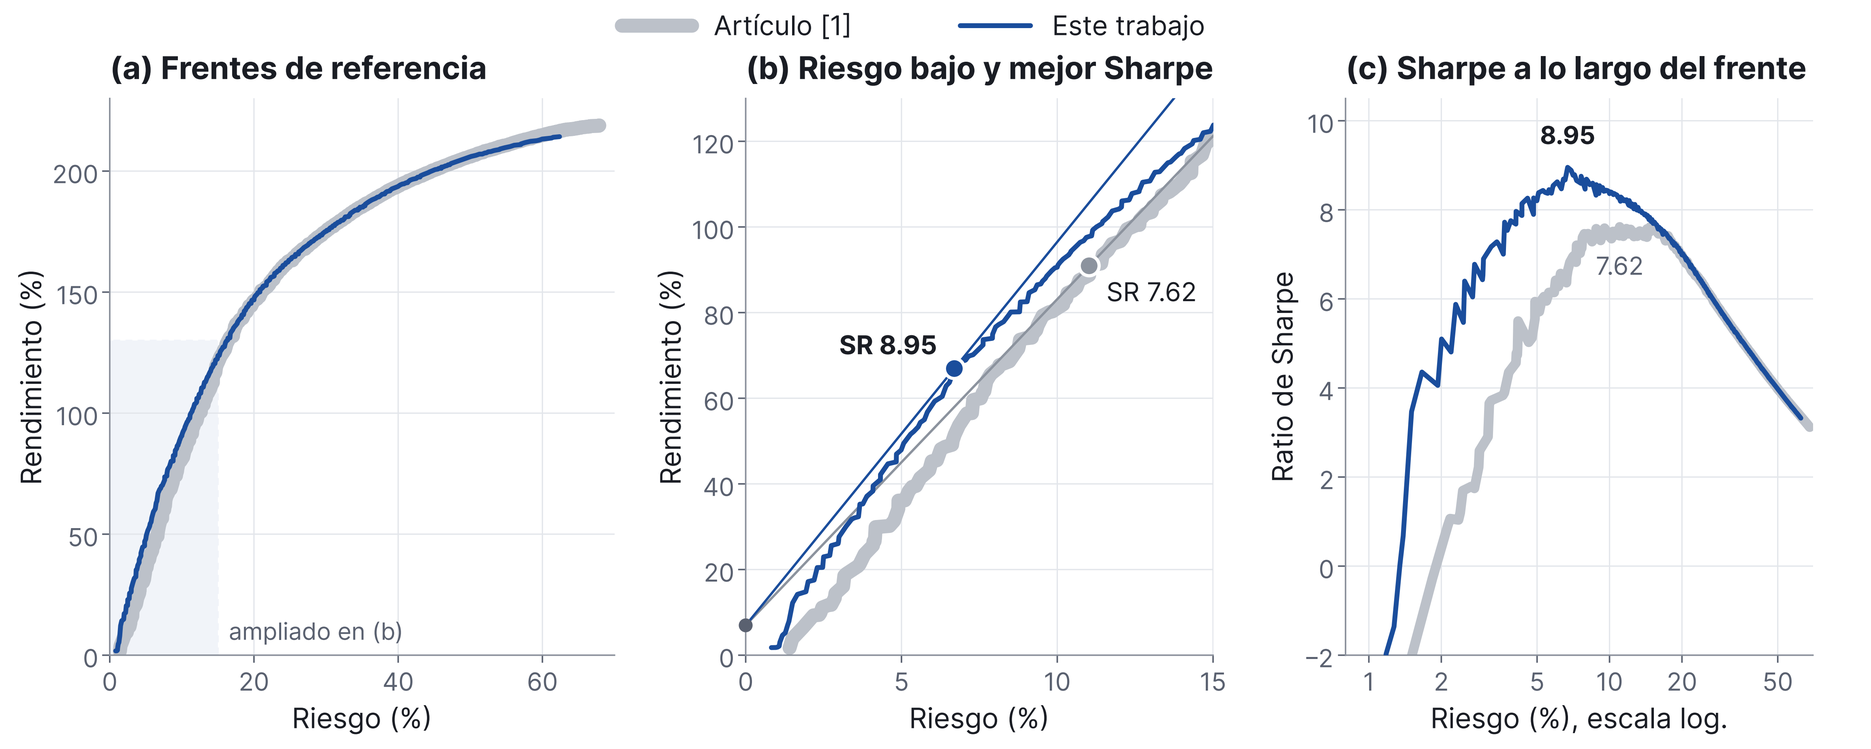
$$\min_{w}\ \gamma\,\sigma^2 - R, \quad \textstyle\sum_j w_j = 1,\ \frac{1}{2k} \le w_j \le \frac{2}{k}, \quad \gamma = 10^{-2+6t}$$

t recorre la frontera eficiente de los activos elegidos.



3 Resultados en la instancia mayor: ALL_20_6000

6 000 activos, $k = 20$, 250 000 evaluaciones por ejecución. Un frente de referencia reúne todas las ejecuciones de todos los algoritmos: 4×30 en el artículo, 3×10 en este trabajo.



(b) Las rectas desde la tasa libre de riesgo $R_f = 6.97\,\%$ tocan cada frente en su mejor ratio de Sharpe SR $= (R - R_f)/\sigma$, su pendiente. (c) Ratio de Sharpe de cada cartera del frente.

8.95
mejor ratio de Sharpe
artículo 7.62 (+18 %)

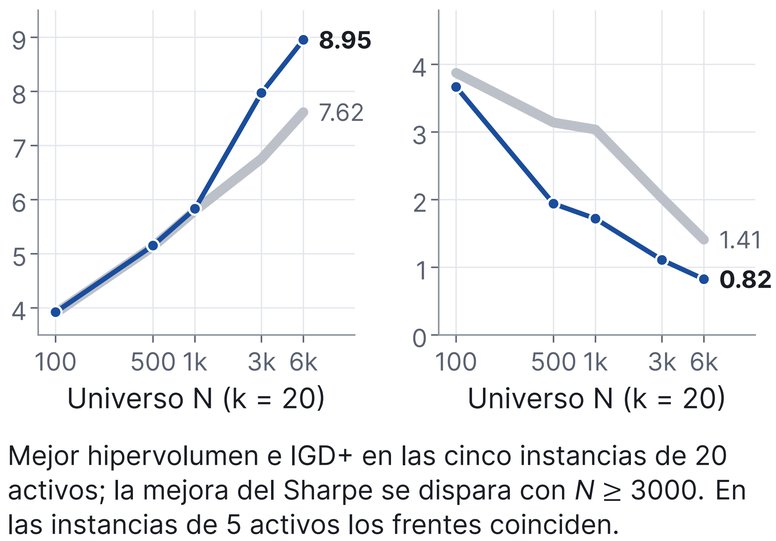
+12 p. p.
rendimiento con 5 % de riesgo
48 % vs 36 %

0.82 %
riesgo mínimo
artículo 1.41 %

0.951
hipervolumen
artículo 0.944

La mejora está bajo el 15 % de riesgo, donde 20 pesos son difíciles de evolucionar; por encima los frentes coinciden (extremo superior: 214 % frente a 219 %).

4 La mejora crece con N



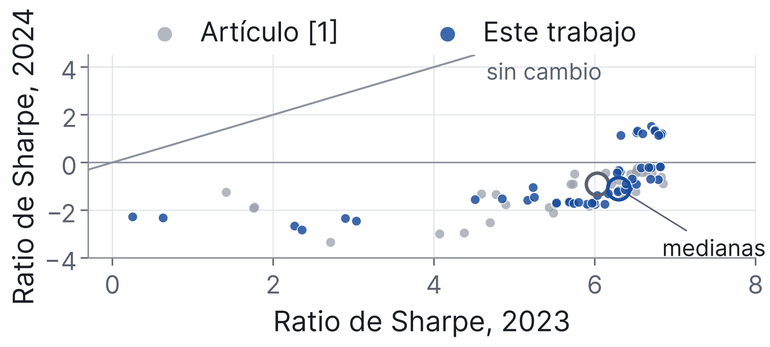
Mejor hipervolumen e IGD+ en las cinco instancias de 20 activos; la mejora del Sharpe se dispara con $N \ge 3000$. En las instancias de 5 activos los frentes coinciden.

5 Robustez y costo

- **Por ejecución**, en las 12 instancias: hipervolumen significativamente mejor que el de la réplica en 33 de 36 pares algoritmo–instancia, nunca peor (Wilcoxon, 5 %). El artículo solo publica frentes combinados.
- **3 empates**, todos en los universos mayores (SMS-EMOA en ALL_20_3000 y ALL_20_6000, NSGA-II en ALL_20_6000). Ahí cada ejecución llega a menos riesgo, pero a un extremo de alto rendimiento más corto: la mutación elige al azar entre 6 000 activos.
- **Costo**: mismo presupuesto de evaluaciones. Los QP subieron el tiempo de las 360 ejecuciones de 63 a 67 min.

6 Fuera de muestra: 2024

Ambos frentes de ALL_20_6000 con precios de Yahoo Finance: carteras con el 80 % de su peso cotizado en 2023–24, sin las de Sharpe negativo en ambos años.



Mediana del Sharpe 2023 → 2024: 6.03 → −0.91 (artículo, 32 de 658 carteras) y 6.30 → −1.10 (este trabajo, 54 de 369). Mejora de optimización, no de pronóstico.

Conclusiones

- Una réplica en pymoo reproduce el orden de los algoritmos y los frentes de referencia del artículo.
- Evolucionar solo los activos (codificación por conjuntos, cruce por posiciones, mutación por intercambio, reparación HRP) y resolver los pesos con un QP da el mejor frente en todas las instancias de 20 activos, y la mejora crece con N: en ALL_20_6000 el mejor ratio de Sharpe pasa de 7.62 a 8.95 con el mismo presupuesto.
- La mejora es dentro de muestra: en 2024 ambos enfoques pierden casi todo su ratio de Sharpe. El siguiente paso son mejores estimaciones de rendimiento y riesgo, más que un mejor optimizador.

Referencias

[1] A. J. Hidalgo-Marín, A. J. Nebro, J. García-Nieto. Efficient Selection of Investment Portfolios in Real-World Markets: A Multi-Objective Optimization Approach. *Algorithms* 2026, 19(1), 20. doi:10.3390/a19010020

[2] M. López de Prado. Building Diversified Portfolios that Outperform Out of Sample. *J. Portfolio Management* 2016, 42(4), 59–69.

[3] D. Goldfarb, A. Idnani. A numerically stable dual method for solving strictly convex quadratic programs. *Math. Programming* 1983, 27, 1–33.

[4] J. Blank, K. Deb. pymoo: Multi-Objective Optimization in Python. *IEEE Access* 2020, 8, 89497–89509.